

Revue bibliographique

Sayan Suos – 22 juillet 2026

Contexte

Le transport de bagages par des véhicules guidés automatisés (AGV) en environnement aéroportuaire soulève des problématiques de navigation multi-agents en environnement dynamique. Au sein de notre projet, l'objectif est de minimiser le temps de transport tout en garantissant l'absence de collision, dans un cadre décentralisé où les agents ne disposent que d'observations locales et ne communiquent pas explicitement entre eux. Dans cette optique, un simulateur est actuellement développé afin de modéliser l'environnement étudié et d'expérimenter différentes approches d'apprentissage par renforcement.

Dans ce contexte, l'apprentissage par renforcement multi-agent (MARL) constitue un cadre naturel pour modéliser les interactions entre AGV. Cependant, il introduit plusieurs limitations notamment : la non-stationnarité induite par l'apprentissage simultané des agents, la difficulté de définir des fonctions de récompense adaptées, l'observabilité partielle de l'environnement, ainsi que des problèmes de passage à l'échelle et d'hétérogénéité des agents [1].

Deep Reinforcement Learning

Afin de traiter ces problématiques, de nombreuses approches reposent sur le deep reinforcement learning (DRL), qui permet de modéliser l'interaction entre un agent et son environnement à l'aide de réseaux de neurones. En robotique, ces méthodes sont largement utilisées pour la navigation autonome et la planification de trajectoires. Le principe consiste à apprendre une politique qui associe à chaque état de l'agent une action, sous forme de commande ou de déplacement. Les algorithmes de DRL peuvent être classés en trois grandes catégories [2] : les méthodes value-based (DQN [3]), qui approximent la fonction de valeur, les méthodes policy-based (PG [3]), qui optimisent directement la politique, et les approches actor-critic, qui combinent les deux. Dans les environnements continus, comme le contrôle de vitesse d'AGV, les méthodes actor-critic sont particulièrement adaptées. En particulier, les approches off-policy telles que SAC ou DDPG permettent une meilleure efficacité d'apprentissage grâce à la réutilisation des données, tandis que les méthodes on-policy comme PPO offrent généralement une plus grande stabilité.

Navigation autonome et planification de trajectoire

Les premières approches étudiées combinent des méthodes classiques de planification de trajectoire avec des techniques d'apprentissage par renforcement. Dans ces approches hybrides, un planificateur global (par exemple A* ou Dijkstra) fournit un chemin de référence, tandis qu'un agent appris localement est chargé d'éviter les collisions à partir d'observations partielles [4, 5]. Cette combinaison permet de concilier une vision globale de la mission avec une capacité d'adaptation locale aux obstacles dynamiques. Des extensions à des espaces d'action continus ont également été proposées [6], se rapprochant davantage du cadre étudié ici, où les agents contrôlent directement leur vitesse. Cependant, ces approches présentent des limitations importantes, notamment leur dépendance à une connaissance préalable de l'environnement (carte) et leur difficulté à s'adapter à des environnements fortement dynamiques ou partiellement inconnus. Par ailleurs, certaines méthodes alternatives reposent uniquement sur l'apprentissage par renforcement, sans planification explicite [7].

Apprentissage multi-agent

Dans le cadre multi-agent, plusieurs stratégies d'apprentissage ont été proposées. Certaines approches reposent sur un apprentissage indépendant (IL), dans lequel un agent est entraîné seul en considérant les autres comme des obstacles dynamiques, puis la politique est déployée sur plusieurs agents [4, 5, 7, 6, 8]. Cette approche est simple à mettre en œuvre, mais ne permet pas de capturer explicitement les interactions entre agents. D'autres travaux s'appuient sur un apprentissage simultané de plusieurs agents, afin de mieux modéliser les phénomènes de coordination et d'interaction [9, 10, 11, 12]. Par ailleurs, certaines méthodes intègrent des modèles inspirés de la navigation humaine, comme les approches basées sur les velocity obstacles, combinées à l'apprentissage par renforcement pour améliorer l'évitement de collision [9], ainsi que des modèles qui prennent en compte les piétons [12, 8].

Lorsque les agents sont homogènes, une autre stratégie consiste à partager les paramètres d'une même politique entre l'ensemble des agents [13]. Cette approche permet de mutualiser les expériences collectées par les différents agents tout en conservant une exécution décentralisée, chaque agent prenant ses décisions à partir de ses propres observations. Le partage de paramètres permet ainsi de limiter le nombre de politiques à entraîner et facilite le passage à un nombre plus important d'agents. Cette approche peut également être appliquée à des espaces d'actions continues, notamment avec Soft Actor-Critic [14].

Approches décentralisées

Les approches centralisées, bien que théoriquement très performantes, présentent des limitations importantes en termes de passage à l'échelle, de coût computationnel et d'adaptabilité en temps réel [15]. Dans ce contexte, notre étude s'oriente vers les approches décentralisées, dans lequel chaque agent prend ses décisions de manière autonome à partir d'observations locales, et dont différentes représentations de l'environnement ont été proposées. Les approches sensor-level utilisent directement les données des capteurs (par exemple lidar) pour prendre des décisions [16, 8], tandis que les approches agent-level reposent sur des représentations internes plus structurées de l'environnement. Des approches hybrides, dites map-based, combinent ces deux niveaux de représentation afin de bénéficier à la fois de la précision des modèles internes et de la réactivité des données capteurs [11].

Techniques d'amélioration de l'apprentissage

Enfin, plusieurs travaux proposent des techniques pour améliorer la robustesse et l'efficacité de l'apprentissage. Le paradigme Centralized Training Decentralized Execution (CTDE) est fréquemment utilisé : il permet d'exploiter des informations globales durant l'apprentissage tout en conservant une exécution décentralisée [17]. Cette approche facilite l'apprentissage mais peut introduire une complexité supplémentaire.

De plus, des stratégies telles que le curriculum learning sont souvent employées, en entraînant les agents sur des scénarios de difficulté croissante afin d'améliorer la convergence et la robustesse des politiques apprises.

Limites de l'état de l'art et perspectives

Malgré les avancées récentes, plusieurs limitations subsistent dans la littérature. Les approches basées uniquement sur le DRL permettent une adaptation locale efficace, mais peinent à garantir des performances globales optimales, notamment en présence de congestion ou de contraintes

structurelles fortes. A l'inverse, les méthodes hybrides combinant planification et apprentissage reposent souvent sur des hypothèses fortes, telles que la connaissance préalable de la carte ou une modélisation discrète de l'environnement.

Par ailleurs, bien que de nombreuses approches traitent le problème multi-agent, peu de travaux considèrent simultanément un cadre continu, décentralisé, sans communication explicite, et avec un objectif d'optimisation globale du temps de mission. Ces contraintes sont pourtant caractéristiques des systèmes industriels.

Dans ce contexte, notre étude vise à explorer les méthodes d'apprentissage par renforcement adaptées à ces contraintes, afin de concilier efficacité d'apprentissage, prise de décision locale et performance globale du système.

Références

- [1] T. Maisonhaute, F. Michel, and J-C. Soulié. État de l’art sur les approches en apprentissage par renforcement multi-agent. In *Journées Francophones sur les Systèmes Multi-Agents (JFSMA)*, pages 99–108, 2024.
- [2] R. Singh, J. Ren, and X. Lin. A review of deep reinforcement learning algorithms for mobile robot path planning. *Vehicles*, 5(4) :1423–1451, 2023.
- [3] A. Amini. MIT 6.S191 : Reinforcement learning, 2025. Vidéo YouTube, consultée le 1er avril 2026.
- [4] R. Reijnen, Y. Zhang, W. P. M. Nuijten, C. Senaras, and M. Goldak. Combining deep reinforcement learning with search heuristics for solving multi-agent path finding in segment-based layouts. In *IEEE Symposium Series on Computational Intelligence (SSCI)*, pages 2647–2654, 2020.
- [5] B. Wang, Z. Liu, Q. Li, and A. Prorok. Mobile robot path planning in dynamic environments through globally guided reinforcement learning. *IEEE Robotics and Automation Letters*, 5(4) :6932–6939, 2020.
- [6] J. Choi, G. Lee, and C. Lee. Reinforcement learning-based dynamic obstacle avoidance and integration of path planning. *International Journal of Intelligent Robotics and Applications*, 14(5) :663–677, 2021.
- [7] Z. Huang, Z. Ren, T. Chen, S. Cai, and C. Xu. Autonomous navigation and collision avoidance for agv in dynamic environments : An enhanced deep reinforcement learning approach with composite rewards and dynamic update mechanisms. *IET Cyber-Systems and Robotics*, 2024.
- [8] J. Liang, U. Patel, A. J. Sathiamoorthy, and D. Manocha. Realtime collision avoidance for mobile robots in dense crowds using implicit multi-sensor fusion and deep reinforcement learning. *arXiv preprint arXiv :2004.03089*, 2020.
- [9] R. Han, S. Chen, S. Wang, Z. Zhang, R. Gao, Q. Hao, and J. Pan. Reinforcement learned distributed multi-robot navigation with reciprocal velocity obstacle shaped rewards. *IEEE Robotics and Automation Letters*, 7(3) :5896–5903, 2022.
- [10] Y. Fan Chen, M. Liu, M. Everett, and J. P. How. Decentralized non-communicating multiagent collision avoidance with deep reinforcement learning. In *2017 IEEE International Conference on Robotics and Automation (ICRA)*, pages 285–292, 2017.
- [11] G. Chen, S. Yao, J. Ma, L. Pan, Y. Chen, P. Xu, J. Ji, and X. Chen. Distributed non-communicating multi-robot collision avoidance via map-based deep reinforcement learning. *Sensors*, 20(17) :4836, 2020.
- [12] E. Escudie, L. Matignon, and J. Saraydaryan. Attention graph for multi-robot social navigation with deep reinforcement learning. *arXiv preprint arXiv :2401.17914*, 2024.
- [13] J. K. Gupta, M. Egorov, and M. J. Kochenderfer. Cooperative Multi-agent Control Using Deep Reinforcement Learning. In *AAMAS Workshops*, 2017.
- [14] H. Ha, J. Xu, and S. Song. Learning a Decentralized Multi-arm Motion Planner, 2020.
- [15] M. De Ryck, M. Versteijhe, and F. Debrouwere. Automated guided vehicle systems, state-of-the-art control algorithms and techniques. *Journal of Manufacturing Systems*, 54 :152–173, 2020.
- [16] P. Long, T. Fan, X. Liao, W. Liu, H. Zhang, and J. Pan. Towards optimally decentralized multi-robot collision avoidance via deep reinforcement learning. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2018.
- [17] S. V. Albrecht. SESSION 3 | Multi-Agent Reinforcement Learning : Foundations and Modern Approaches | IAAA-CSIC Course, 2024. Vidéo YouTube, consultée le 20 avril 2026.