

Récapitulatif du 29 avril 2026

Travail réalisé : Étude de 6 références portant sur notre problématique, avec une attention particulière sur les axes suivants : le paradigme Centralized Training, Decentralized Execution (CTDE), la prise en compte des interactions avec les piétons dans des environnements dynamiques, et l'intégration d'approches complémentaires telles que les Velocity Obstacles (VO) et les Graph Neural Networks (GNN).

- S. V. Albrecht. SESSION 3 | Multi-Agent Reinforcement Learning : Foundations and Modern Approaches | IAAA-CSIC Course, 2024. Vidéo YouTube, consultée le 20 avril 2026.
- J. Liang, U. Patel, A. J. Sathiamoorthy, and D. Manocha. Realtime collision avoidance for mobile robots in dense crowds using implicit multi-sensor fusion and deep reinforcement learning. arXiv preprint arXiv :2004.03089, 2020.
- E. Escudie, L. Maignon, and J. Saraydaryan. Attention graph for multi-robot social navigation with deep reinforcement learning. arXiv preprint arXiv :2401.17914, 2024.
- R. Han, S. Chen, S. Wang, Z. Zhang, R. Gao, Q. Hao, and J. Pan. Reinforcement learned distributed multi-robot navigation with reciprocal velocity obstacle shaped rewards. IEEE Robotics and Automation Letters, 7(3) :5896–5903, 2022.
- Y. Fan Chen, M. Liu, M. Everett, and J. P. How. Decentralized non-communicating multiagent collision avoidance with deep reinforcement learning. In 2017 IEEE International Conference on Robotics and Automation (ICRA), pages 285–292, 2017.
- G. Chen, S. Yao, J. Ma, L. Pan, Y. Chen, P. Xu, J. Ji, and X Chen. Distributed non-communicating multi-robot collision avoidance via map-based deep reinforcement learning. Sensors, 20(17) :4836, 2020.

Bilan : Les nouvelles approches étudiées récemment semblent pertinentes, mais parfois assez complexes à mettre en œuvre dans le cadre d'une première expérimentation en apprentissage par renforcement.

Le papier "*Decentralized non-communicating multiagent collision avoidance with deep reinforcement learning*" propose une approche intéressante, qui combine apprentissage supervisé et apprentissage par renforcement. Elle permet un entraînement assez rapide (3h) et obtient de meilleures performances que ORCA. Toutefois, elle repose sur des hypothèses fortes qui peuvent limiter sa généralisation. Elle reste néanmoins pertinente dans le cas où le temps d'entraînement constitue une contrainte importante.

Par ailleurs, le paradigme CTDE est intéressant pour améliorer la robustesse des politiques apprises, en particulier dans le cas d'algorithmes actor-critic. Cependant, son utilisation introduit une complexité supplémentaire lors de la phase d'entraînement.

Proposition de plan expérimental : Afin de structurer la suite du travail, une démarche progressive en trois étapes est envisagée :

1. **Etude d'un cas simple mono-agent :** Mise en place d'un algorithme de référence, tel que SAC, adapté aux espaces continus, pour un seul agent qui navigue dans un environnement avec des obstacles statiques et dynamiques.

2. **Extension au cas multi-agent (apprentissage indépendant)** : Entraînement d'une politique sur agent unique, puis déploiement sur plusieurs agents, en considérant les autres comme des obstacles dynamiques.
3. **Exploration des approches plus avancées** : Soit une approche hybride qui combine planification globale et apprentissage local, soit une approche entièrement DRL avec entraînement simultané de plusieurs agents.

Dans le contexte de l'apprentissage par renforcement, il est nécessaire de définir les différents éléments du problème :

- **Espace des états** : L'état de l'agent doit contenir les informations pertinentes pour la prise de décisions, soit : la position relative à l'objectif, la vitesse actuelle (linéaire et angulaire), l'orientation de l'agent, et une représentation locale de l'environnement sous forme d'une carte encodée sur 1 ou plusieurs frames.
- **Espace des actions** : Les actions correspondent aux commandes envoyées à l'AGV, soit la vitesse linéaire et la vitesse angulaire.
- **Fonction de récompense** : La fonction de récompense doit refléter les objectifs du système, tout en guidant efficacement l'apprentissage. Elle peut inclure : une récompense liée à la progression vers l'objectif, une pénalisation des variations brusques de vitesses, une pénalité en cas de collision, et une pénalité associée au non-respect des distances de sécurité ou temps de collision.