

Récapitulatif du 3 juillet 2026

État actuel du simulateur ([Github](#)) :

Plusieurs évolutions ont été apportées à l'environnement d'apprentissage, à la fonction de récompense ainsi qu'au rapport sur la modélisation et sur le protocole expérimental.

L'espace des observations a été modifié afin de fournir des informations plus directement exploitables par la politique. La position relative de la cible a été remplacée par la distance à l'objectif ainsi que par l'erreur d'orientation entre l'agent et sa cible, ce qui facilite l'apprentissage.

La fonction de récompense a également été revue afin de mieux guider l'apprentissage. La récompense de progression dépend désormais de la proximité des obstacles, et les vitesses linéaires élevées sont encouragées afin d'éviter les comportements trop hésitants ou les situations de stagnation.

Un premier curriculum d'apprentissage composé de huit expériences a été mis en place. Les résultats obtenus sont encourageants, mais plusieurs limites apparaissent : les scénarios aléatoires restent difficiles à apprendre, le curriculum ne prend actuellement en compte que des obstacles statiques et reste relativement éloigné des situations finales visées.

La politique obtenue à l'issue de la huitième expérience est ensuite évaluée sur cinq environnements représentatifs des principaux types de scénarios étudiés (random, warehouse et crossing), tout en conservant une complexité raisonnable au regard du curriculum d'apprentissage actuel.

Après vérification, le temps d'entraînement reste relativement faible : il est de l'ordre de **30 secondes pour 10 000 itérations** en moyenne sur les scénarios actuellement utilisés, soit environ **12 à 13 minutes pour 250 000 itérations**. Ce temps peut toutefois varier selon la complexité du scénario (nombre d'agents, d'obstacles, durée des épisodes, etc.). En revanche, le nombre d'itérations réellement nécessaires avant convergence dépend fortement de la qualité et de la progression du curriculum d'apprentissage. Un curriculum mieux conçu pourrait permettre d'obtenir une politique performante en un nombre d'itérations plus faible.

Points à discuter / à revoir :

- Définir précisément le comportement des obstacles dynamiques, aussi bien durant l'entraînement que durant l'évaluation (déplacement selon A* ou selon une politique apprise).
- Revoir le curriculum d'apprentissage en améliorant la progression de la difficulté des scénarios et en intégrant progressivement des obstacles dynamiques.
- Étudier l'ajout d'un historique des observations locales (par exemple les trois dernières cartes locales au lieu d'une seule) afin de permettre à l'agent d'estimer le mouvement des obstacles dynamiques.
- Améliorer la représentation de certains résultats, notamment la comparaison des politiques entraînées sur l'ensemble des scénarios, par exemple à l'aide d'une heatmap plutôt que d'un tableau.

- Discuter de la pertinence d'utiliser des seuils de collision et d'atteinte identiques entre l'entraînement et l'évaluation (le seuil actuel est fixé à 0,5 m).
- Prendre en compte les commentaires évoqués lors de la précédente réunion mais qui n'ont pas encore été implémentés, notamment la poursuite ou non d'un épisode après une collision ainsi que l'adaptation dynamique de la taille de la carte d'observation en fonction de la vitesse de l'agent.
- Évaluer la politique apprise dans des scénarios multi-agents.
- Mettre à jour le README du projet.

Bilan :

L'entraînement directement multi-agent apparaît toujours comme un objectif ambitieux dans le cadre du projet. La stratégie retenue consiste donc à adopter une approche progressive. Dans un premier temps, un agent sera entraîné seul dans un environnement intégrant des obstacles dynamiques. Une partie de ces obstacles appliquera la politique apprise, tandis que les autres continueront de suivre des trajectoires planifiées par A*. L'historique des cartes locales sera également intégré afin d'améliorer la perception du mouvement des obstacles.

La politique obtenue sera ensuite évaluée dans des scénarios multi-agents afin d'étudier ses capacités de généralisation. Enfin, un entraînement véritablement multi-agent sera envisagé dans un second temps, en s'intéressant plus particulièrement à la prise en compte des interactions entre agents et à leur impact sur l'apprentissage.

Commentaires suite à la réunion :

- Reprendre et compléter le rapport :
 - préciser la relation entre steps et temps ;
 - indiquer les caractéristiques de la machine utilisée ainsi que les temps d'entraînement observés ;
 - ajouter un glossaire des principales notations utilisées dans le rapport ;
 - expliquer et justifier davantage certains choix de modélisation, en particulier ceux concernant la fonction de récompense.
- Préparer une documentation du simulateur afin de faciliter sa prise en main
- Améliorer le curriculum d'apprentissage, notamment pour résoudre les difficultés rencontrées sur les scénarios aléatoires en proposant une progression de la difficulté plus adaptée.
- Poursuivre l'entraînement en mono-agent en intégrant :
 - un historique des cartes locales afin de permettre l'estimation du mouvement des obstacles ;
 - des obstacles dynamiques, dont une partie suivra la politique apprise tandis que l'autre continuera d'utiliser des trajectoires générées par A*.

La politique obtenue sera ensuite évaluée en multi-agent.
- Étudier un véritable entraînement multi-agent (avec 2 agents), en réfléchissant notamment à la manière de prendre en compte les interactions entre agents.